

Regressão Linear Múltipla — Análise Completa da Base Credit

Estatística Aplicada — Universidade Federal de Campina Grande (UFCG)

Gustavo Maia Nogueira e Telmano Leite Japiassú Neto

03/08/2026

Ideia central. Regressão múltipla não é uma sequência de botões, é um argumento científico. Definimos uma pergunta, explicitamos um modelo, confrontamos suas suposições com os dados, avaliamos incerteza e só então comunicamos o que o modelo permite e o que ele não permite concluir.

1 Visão geral da análise

1.1 Preparação do ambiente

Instale os pacotes uma única vez. Depois, abra o arquivo `.Rmd` no RStudio e use **Knit**, ou execute `rmarkdown::render()`. No HTML, os códigos ficam recolhidos: clique em **Code** para visualizá-los. Para reproduzir ou alterar a análise, execute/renderize o documento inteiro na ordem apresentada, pois cada etapa usa objetos criados nas etapas anteriores.

1.2 Objetivos da análise

Esta análise foi estruturada para:

1. transformar uma pergunta substantiva em uma equação de regressão;
2. distinguir variável resposta, preditores numéricos e preditores categóricos;
3. realizar uma análise exploratória orientada ao modelo;
4. ajustar e interpretar uma regressão linear múltipla em R;
5. verificar linearidade, independência, homocedasticidade, normalidade aproximada, multicolinearidade e influência;
6. comparar cinco modelos usando teste F, R^2 ajustado, AIC, BIC e parcimônia;
7. interpretar corretamente variáveis categóricas e categorias de referência;
8. diferenciar intervalo de confiança da média e intervalo de previsão individual;
9. reconhecer multicolinearidade, extrapolação e linguagem causal indevida;
10. selecionar um modelo com base no conjunto das evidências e produzir uma conclusão defensável.

1.3 O mapa do processo

Etapa	Pergunta que guia a etapa	Produto
1. Problema	O que queremos explicar ou prever?	pergunta, população e unidade de análise

Etapa	Pergunta que guia a etapa	Produto
2. Dados	As variáveis medem o que precisamos?	dicionário, qualidade e exploração
3. Especificação	Que relação estamos supondo?	fórmula, termos e interações justificadas
4. Ajuste	Quais coeficientes melhor reproduzem os dados?	modelo estimado e incerteza
5. Comparação preliminar	Qual modelo tem melhor ajuste e quais termos acrescentam informação?	tabela comparativa, teste F e candidato ao diagnóstico
6. Diagnóstico	O candidato respeita os pressupostos de forma razoável?	resíduos, influência, VIF e gráficos auxiliares
7. Decisão	Qual especificação é mais defensável para cada objetivo?	melhor ajuste, alternativa interpretável e justificativa
8. Comunicação	O que aprendemos e com quais limites?	conclusão, intervalos e próximos passos

2 A pergunta vem antes do modelo

Usaremos **Balance**, o saldo devedor do cartão de crédito, em dólares, como resposta. Queremos investigar e prever esse saldo a partir de todas as variáveis disponíveis: renda, limite de crédito, classificação de crédito, número de cartões, idade, anos de educação, gênero, condição de estudante, estado civil e etnia.

Uma pergunta bem formulada seria:

Entre clientes com o mesmo perfil financeiro e demográfico, como o saldo devedor esperado varia com cada preditor, e quão bem o modelo prevê novos clientes?

Essa frase já contém duas metas diferentes:

- **inferência/explicação:** interpretar relações condicionais e sua incerteza;
- **previsão:** estimar valores para novas observações com baixo erro.

“Melhor modelo” não é uma propriedade absoluta. Um modelo pode ser excelente para previsão e ruim para interpretação; outro pode ser transparente e estável, mas perder um pouco de acurácia. Antes de comparar modelos, declare o objetivo.

2.1 O modelo matemático

A estratégia será começar com um modelo que inclui **todos** os preditores disponíveis e, progressivamente, remover variáveis que não contribuem de forma significativa. Para a observação i , o modelo completo inicial é

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_p X_{pi} + \varepsilon_i,$$

em que:

- Y_i é o saldo devedor observado no cartão de crédito;

- β_0 é o valor esperado de Y quando os preditores valem zero;
- β_j é a mudança média esperada em Y para uma unidade adicional de X_j , **mantendo os demais preditores constantes**;
- ε_i representa tudo o que o modelo não explica.

Quando incluímos variáveis categóricas, o R cria variáveis indicadoras (*dummies*) comparando cada nível com uma categoria de referência.

2.2 Suposições: o que realmente precisamos verificar

Suposição	Significado operacional	Como verificar	O que fazer se falhar
Linearidade	a média condicional de Y é linear nos parâmetros	resíduos vs. ajustados; resíduos parciais	transformação, polinômio, spline ou interação justificada
Independência	erros de unidades distintas não são correlacionados	desenho da coleta; ordem/tempo/grupos	modelos mistos, séries temporais, erros agrupados
Variância aproximadamente constante	dispersão dos erros é semelhante ao longo da média	resíduos vs. ajustados; escala-localização	transformação, erros robustos, WLS
Normalidade aproximada dos erros	necessária principalmente para inferência exata em amostras pequenas	QQ-plot; forma dos resíduos	bootstrap, erros robustos, investigar modelo/outliers
Ausência de colinearidade prejudicial	preditores não carregam quase a mesma informação	VIF/GVIF; estabilidade dos coeficientes	reformular, combinar, centrar, regularizar, coletar mais dados
Ausência de influência excessiva	nenhuma observação domina o ajuste	alavancagem e distância de Cook	verificar dado, relatar sensibilidade; nunca excluir automaticamente
Especificação adequada	termos importantes não foram omitidos	teoria, resíduos, interações, validação	reespecificar com justificativa substantiva

Cheque conceitual. Normalidade dos preditores não é pressuposto da regressão linear. O foco é a distribuição dos erros condicionais, e nem toda pequena violação invalida o modelo.

3 Conhecendo a base Credit

3.1 Estrutura, unidade e qualidade

```
## Rows: 400
## Columns: 13
## $ ID      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 1~
## $ Income  <dbl> 14.89, 106.03, 104.59, 148.92, 55.88, 80.18, 21.00, 71.41, 1~
## $ Limit   <int> 3606, 6645, 7075, 9504, 4897, 8047, 3388, 7114, 3300, 6819, ~
```

```
## $ Rating    <int> 283, 483, 514, 681, 357, 569, 259, 512, 266, 491, 589, 138, ~
## $ Cards     <int> 2, 3, 4, 3, 2, 4, 2, 2, 5, 3, 4, 3, 1, 1, 2, 3, 3, 3, 1, 2, ~
## $ Age       <int> 34, 82, 71, 36, 68, 77, 37, 87, 66, 41, 30, 64, 57, 49, 75, ~
## $ Education <int> 11, 15, 11, 11, 16, 10, 12, 9, 13, 19, 14, 16, 7, 9, 13, 15, ~
## $ Gender    <fct> Male, Female, Male, Female, Male, Male, Female, Male, Female~
## $ Student   <fct> No, Yes, No, No, No, No, No, No, No, No, Yes, No, No, No, No~
## $ Married   <fct> Yes, Yes, No, No, Yes, No, No, No, No, No, Yes, Yes, No, Yes, Ye~
## $ Ethnicity <fct> Caucasian, Asian, Asian, Asian, Caucasian, Caucasian, Africa~
## $ Balance   <int> 333, 903, 580, 964, 331, 1151, 203, 872, 279, 1350, 1407, 0, ~
## $ id       <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 1~
```

Cada linha representa um cliente; o saldo devedor está em dólares. Há 400 observações.

Os dados foram divididos em **280 observações de treinamento** (70%) e **120 de teste** (30%). Toda a exploração, ajuste e seleção de modelos usará apenas o conjunto de treinamento. O conjunto de teste fica reservado para avaliação final da capacidade preditiva do modelo escolhido.

variavel	tipo	papel	definicao
Balance	numérica	resposta	saldo devedor do cartão de crédito (US\$)
Income	numérica	preditor	renda anual (milhares de US\$)
Limit	numérica	preditor	limite de crédito (US\$)
Rating	numérica	preditor	classificação de crédito
Cards	numérica	preditor	número de cartões de crédito
Age	numérica	preditor	idade (anos)
Education	numérica	preditor	anos de educação formal
Gender	categórica	preditor	gênero (Male / Female)
Student	categórica	preditor	status de estudante (Yes / No)
Married	categórica	preditor	estado civil (Yes / No)
Ethnicity	categórica	preditor	etnia (African American / Asian / Caucasian)
ID	inteira	identificador	identificador original do cliente

```
## observacoes duplicatas_exatas valores_ausentes estudantes nao_estudantes
## 1          400              0              0          40          360
```

3.2 Estatísticas descritivas

variavel	n	media	dp	minimo	q1	mediana	q3	maximo
Age	400	55.67	17.25	23.00	41.75	56.00	70.00	98.0
Balance	400	520.02	459.76	0.00	68.75	459.50	863.00	1999.0
Cards	400	2.96	1.37	1.00	2.00	3.00	4.00	9.0
Education	400	13.45	3.13	5.00	11.00	14.00	16.00	20.0
Income	400	45.22	35.24	10.35	21.01	33.12	57.47	186.6
Limit	400	4735.60	2308.20	855.00	3088.00	4622.50	5872.75	13913.0
Rating	400	354.94	154.72	93.00	247.25	344.00	437.25	982.0

3.3 O saldo devedor segundo as variáveis categóricas

Antes de ajustar qualquer modelo, examinamos graficamente se cada variável categórica separa o saldo devedor. Essa inspeção orienta quais variáveis merecem entrar no modelo e antecipa quais provavelmente não terão efeito significativo.




Figura 1: Saldo devedor por condição de estudante.

Há uma separação clara. Os estudantes carregam saldos devedores bem mais elevados do que os não estudantes. Essa variável parece ter potencial para contribuir significativamente no modelo.




Figura 2: Saldo devedor por gênero.

Não há separação visível entre os gêneros. As medianas, os quartis e a dispersão são praticamente idênticos. Provavelmente essa variável não contribuirá de forma significativa.

As distribuições de casados e não casados se sobrepõem amplamente. Não há sinal de que o estado civil, por si só, esteja associado ao saldo devedor.

As três etnias apresentam medianas, dispersões e formatos de distribuição muito semelhantes. A

Saldo devedor por estado civil

As distribuições são semelhantes para casados e não casados




Figura 3: Saldo devedor por estado civil.

Saldo devedor por etnia

As três etnias apresentam distribuições praticamente sobrepostas




Figura 4: Saldo devedor por etnia.

exploração gráfica não sugere uma associação relevante entre etnia e saldo devedor.

Resumo da inspeção categórica: Dos quatro preditores categóricos, apenas **Student** apresenta separação clara do saldo devedor. **Gender**, **Married** e **Ethnicity** não mostram diferenças visuais importantes. Essa observação será confirmada (ou não) pelos p-valores no modelo completo.

3.4 Relações bivariadas não contam a história completa




Figura 5: Matriz de pares: distribuições na diagonal, correlações no triângulo superior e dispersões no triângulo inferior.

##	Balance	Income	Limit	Rating	Cards	Age	Education
## Balance	1.000	0.464	0.862	0.864	0.086	0.002	-0.008
## Income	0.464	1.000	0.792	0.791	-0.018	0.175	-0.028
## Limit	0.862	0.792	1.000	0.997	0.010	0.101	-0.024
## Rating	0.864	0.791	0.997	1.000	0.053	0.103	-0.030
## Cards	0.086	-0.018	0.010	0.053	1.000	0.043	-0.051
## Age	0.002	0.175	0.101	0.103	0.043	1.000	0.004
## Education	-0.008	-0.028	-0.024	-0.030	-0.051	0.004	1.000

Dois padrões se destacam na matriz de correlação:

1. **Limit** e **Rating** têm correlação muito alta (0,997), sinalizando possível multicolinearidade severa se

ambas entrarem no modelo.

2. **Balance** tem correlação forte com **Limit** (0,862) e **Rating** (0,864), moderada com **Income** (0,464), e fraca com **Cards**, **Age** e **Education**.

Dois preditores positivamente correlacionados não precisam ter coeficientes múltiplos com o mesmo sinal. Cada coeficiente é um efeito parcial, condicionado aos demais termos. Uma inversão de sinal pode revelar colinearidade, confundimento ou uma pergunta condicional diferente, não uma contradição lógica automática.




Figura 6: A linha agregada mistura diferenças entre estudantes e não estudantes e relações dentro de cada grupo.

4 Construção progressiva dos cinco modelos

A estratégia adotada é começar com um **modelo completo** contendo todas as variáveis disponíveis e, a cada passo, remover as que não contribuem de forma significativa, verificando com os p-valores, os gráficos exploratórios e, quando necessário, testes F. Ao final, chegaremos a um modelo enxuto e defensável.

Os cinco modelos serão ajustados com as 280 observações do conjunto de treinamento. A decisão final será tomada somente depois que todos tiverem sido estimados, interpretados e comparados.

4.1 Como ler a saída de `lm()`

- **Estimate:** estimativa de cada coeficiente β_j ;
- **Std. Error:** erro-padrão, que mede a incerteza da estimativa;
- **t value e p-valor:** teste de $H_0 : \beta_j = 0$, condicionado aos demais termos do modelo;
- **Residual standard error:** escala típica dos resíduos, em dólares;
- **Multiple R^2 :** proporção da variabilidade observada explicada pelo ajuste;
- **Adjusted R^2 :** versão do R^2 que considera o número de parâmetros;
- **F-statistic:** teste global do modelo contra um ajuste somente com intercepto.

O coeficiente estimado e seu erro-padrão cumprem papéis diferentes. A estimativa indica o tamanho e o sentido da associação; o erro-padrão indica a precisão dessa estimativa. Em termos simples, ele resume quanto a estimativa tenderia a variar se repetíssemos a coleta e o ajuste muitas vezes sob condições semelhantes. O valor de t é calculado por $t = \hat{\beta}/EP(\hat{\beta})$: para um mesmo coeficiente, maior erro-padrão implica menor precisão e menor evidência contra $H_0 : \beta = 0$.

4.2 Variáveis categóricas como contrastes

Como o modelo completo já inclui variáveis categóricas, é preciso entender como o R as representa. Para cada fator, o R escolhe uma **categoria de referência** e cria variáveis indicadoras (*dummies*) para as demais.

Student possui duas categorias; o R usa **No** como referência:

Condição	Z_1 : StudentYes
Não estudante	0
Estudante	1

Ethnicity possui três categorias; o R usa **African American** como referência:

Etnia	Z_2 : Asian	Z_3 : Caucasian
African American	0	0
Asian	1	0
Caucasian	0	1

Gender e **Married** seguem a mesma lógica, cada uma com uma indicadora.

```
## [1] "No" "Yes"

##      Yes
## No    0
## Yes   1

## [1] "African American" "Asian"          "Caucasian"

##              Asian Caucasian
## African American    0         0
## Asian                1         0
## Caucasian            0         1

## [1] "Female" "Male"

##      Male
## Female    0
## Male      1
```

Assim, cada variável categórica contribui com $k - 1$ coeficientes, em que k é o número de categorias, sem criar dependência linear perfeita com o intercepto.

4.3 Modelo 1 — modelo completo (todas as variáveis)

O primeiro ajuste inclui **todos** os preditores disponíveis. A ideia é partir do modelo mais abrangente e, a partir da sua saída, identificar quais variáveis não contribuem:

```
##
## Call:
## lm(formula = Balance ~ Income + Limit + Rating + Cards + Age +
##     Education + Gender + Student + Married + Ethnicity, data = treino)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -172.5   -74.7   -11.8    55.9   333.3
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)   -497.385     45.914  -10.83 < 0.0000000000000002 ***
## Income         -7.961       0.282  -28.20 < 0.0000000000000002 ***
## Limit           0.209       0.041    5.09   0.00000068 ***
## Rating          0.896       0.613    1.46   0.14527
## Cards          20.239       5.347    3.79   0.00019 ***
## Age            -0.216       0.374   -0.58   0.56480
## Education      -2.276       2.000   -1.14   0.25606
## GenderMale     17.264      12.122    1.42   0.15557
## StudentYes     435.935      20.385   21.38 < 0.0000000000000002 ***
## MarriedYes     -18.113      12.701   -1.43   0.15498
## EthnicityAsian  16.416      17.810    0.92   0.35750
## EthnicityCaucasian 15.363      15.720    0.98   0.32930
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 101 on 268 degrees of freedom
## Multiple R-squared:  0.956, Adjusted R-squared:  0.954
## F-statistic: 525 on 11 and 268 DF, p-value: <0.0000000000000002
```

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-497.385	45.914	-10.833	0.000	-587.784	-406.987
Income	-7.961	0.282	-28.203	0.000	-8.516	-7.405
Limit	0.209	0.041	5.088	0.000	0.128	0.290
Rating	0.896	0.613	1.461	0.145	-0.312	2.103
Cards	20.239	5.347	3.785	0.000	9.712	30.766
Age	-0.216	0.374	-0.576	0.565	-0.953	0.521
Education	-2.276	2.000	-1.138	0.256	-6.214	1.661
GenderMale	17.264	12.122	1.424	0.156	-6.603	41.130
StudentYes	435.935	20.385	21.385	0.000	395.800	476.070
MarriedYes	-18.113	12.701	-1.426	0.155	-43.119	6.892
EthnicityAsian	16.416	17.810	0.922	0.358	-18.650	51.482

EthnicityCaucasian	15.363	15.720	0.977	0.329	-15.587	46.312
--------------------	--------	--------	-------	-------	---------	--------

4.3.1 O que é VIF?

VIF significa *Variance Inflation Factor*, ou **fator de inflação da variância**. Para o preditor X_j ,

$$VIF_j = \frac{1}{1 - R_j^2},$$

em que R_j^2 vem de uma regressão auxiliar de X_j contra todos os outros preditores. Se os demais preditores quase conseguem reconstruir X_j , esse R_j^2 fica próximo de 1 e o VIF cresce.

O VIF informa por quanto a **variância** estimada de $\hat{\beta}_j$ foi inflada pela relação linear entre os preditores. A raiz quadrada do VIF informa aproximadamente por quanto o **erro-padrão** foi inflado em comparação com uma situação ideal de preditores não correlacionados. A tolerância é $1/VIF$; valores pequenos significam que resta pouca informação exclusiva naquele preditor.

variavel	VIF	raiz do VIF	tolerancia	R ² da regressão auxiliar
Income	2.734	1.654	0.366	0.634
Limit	247.388	15.729	0.004	0.996
Rating	248.726	15.771	0.004	0.996
Cards	1.439	1.200	0.695	0.305
Age	1.048	1.024	0.954	0.046
Education	1.049	1.024	0.953	0.047
Gender	1.012	1.006	0.988	0.012
Student	1.031	1.015	0.970	0.030
Married	1.049	1.024	0.953	0.047
Ethnicity	1.061	1.030	0.942	0.058

4.3.2 Comentários e observações sobre o Modelo 1

O modelo é globalmente significativo e apresenta R^2 ajustado igual a 0,954, ou aproximadamente 95,4% da variabilidade explicada.

Dois problemas ficam evidentes:

1. **Multicolinearidade severa entre Limit e Rating.** Os VIF dessas variáveis são extremamente altos: a correlação de 0,997 faz com que cada uma possa ser quase perfeitamente reconstruída pela outra. Isso infla os erros-padrão e torna os coeficientes individuais instáveis. A solução é manter apenas uma delas. Como **Limit** tem interpretação mais direta (é o próprio limite do cartão em dólares), **removeremos Rating** no próximo passo.
2. **Muitas variáveis com p-valor alto.** Várias variáveis apresentam p-valores bem acima de 0,05, indicando que, condicionadas aos demais termos, não trazem evidência de contribuição para explicar o saldo devedor. Isso é coerente com a exploração gráfica, que já havia mostrado pouca separação para **Gender**, **Married** e **Ethnicity**.

Regras como “VIF maior que 5 exige atenção” e “VIF maior que 10 indica colinearidade forte” são referências práticas, não leis universais. Aqui, os valores extremos de **Limit** e **Rating** e a correlação

quase perfeita entre ambas contam uma história clara: os efeitos individuais dessas duas variáveis são impossíveis de separar com estabilidade.

Leitura correta da multicolinearidade: O modelo ainda pode ajustar bem os dados. O principal prejuízo está na separação e interpretação dos efeitos individuais, nos erros-padrão e na estabilidade dos coeficientes.

4.4 Modelo 2 — remoção de Rating (colinearidade)

A multicolinearidade entre `Limit` e `Rating` é o problema mais urgente. Removemos `Rating` (a variável com interpretação menos direta) e mantivemos todo o restante:

```
##
## Call:
## lm(formula = Balance ~ Income + Limit + Cards + Age + Education +
##     Gender + Student + Married + Ethnicity, data = treino)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -174.0   -78.0   -10.7    53.8   338.1
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept)   -468.45366    41.50959  -11.29 < 0.0000000000000002 ***
## Income         -7.94293     0.28260  -28.11 < 0.0000000000000002 ***
## Limit          0.26847     0.00427   62.90 < 0.0000000000000002 ***
## Cards         24.47707     4.50067    5.44    0.00000012 ***
## Age          -0.21943     0.37525   -0.58     0.56
## Education     -2.81224     1.97005   -1.43     0.15
## GenderMale    16.51008    12.13650    1.36     0.17
## StudentYes    438.26977    20.36517   21.52 < 0.0000000000000002 ***
## MarriedYes   -15.56544    12.60683   -1.23     0.22
## EthnicityAsian 13.82148    17.75876    0.78     0.44
## EthnicityCaucasian 15.09044    15.75153    0.96     0.34
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 101 on 269 degrees of freedom
## Multiple R-squared:  0.955, Adjusted R-squared:  0.954
## F-statistic: 575 on 10 and 269 DF, p-value: <0.0000000000000002
```

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-468.454	41.510	-11.285	0.000	-550.179	-386.729
Income	-7.943	0.283	-28.107	0.000	-8.499	-7.387
Limit	0.268	0.004	62.901	0.000	0.260	0.277
Cards	24.477	4.501	5.439	0.000	15.616	33.338
Age	-0.219	0.375	-0.585	0.559	-0.958	0.519

Education	-2.812	1.970	-1.427	0.155	-6.691	1.066
GenderMale	16.510	12.137	1.360	0.175	-7.385	40.405
StudentYes	438.270	20.365	21.521	0.000	398.174	478.365
MarriedYes	-15.565	12.607	-1.235	0.218	-40.386	9.255
EthnicityAsian	13.821	17.759	0.778	0.437	-21.142	48.785
EthnicityCaucasian	15.090	15.752	0.958	0.339	-15.922	46.102

variavel	VIF	raiz do VIF	tolerancia
Income	2.729	1.652	0.366
Limit	2.664	1.632	0.375
Cards	1.015	1.008	0.985
Age	1.048	1.024	0.954
Education	1.014	1.007	0.986
Gender	1.010	1.005	0.990
Student	1.024	1.012	0.976
Married	1.030	1.015	0.971
Ethnicity	1.046	1.023	0.956

4.4.1 Comentários e observações sobre o Modelo 2

Com a remoção de **Rating**, o problema de colinearidade foi resolvido: nenhum VIF está em faixa preocupante. O R^2 ajustado permanece em 0,954, mostrando que **Rating** não acrescentava informação que **Limit** já não fornecesse.

Agora podemos examinar os p-valores com mais confiança, pois os erros-padrão não estão mais inflados pela colinearidade:

- **Student** é altamente significativo (coerente com a separação clara nos boxplots).
- **Income** e **Limit** são significativos.
- **Gender**, **Married**, **Ethnicity**, **Education**, **Cards** e **Age** apresentam p-valores altos, sem evidência de contribuição significativa.

Os boxplots da exploração já haviam indicado que **Gender**, **Married** e **Ethnicity** não separam o saldo devedor. Os p-valores no modelo confirmam essa observação. No próximo passo, removemos essas três variáveis categóricas de uma vez.

4.5 Modelo 3 — remoção de **Gender**, **Married** e **Ethnicity**

A exploração gráfica mostrou que essas três variáveis categóricas não separam o saldo devedor, e os p-valores no Modelo 2 confirmam que elas não contribuem significativamente na presença dos demais preditores. Removemos as três:

```
##
## Call:
## lm(formula = Balance ~ Income + Limit + Cards + Age + Education +
##      Student, data = treino)
##
## Residuals:
```

```
##      Min      1Q  Median      3Q      Max
## -184.4  -79.9  -14.6   52.1  328.1
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -457.40835    38.62095  -11.84 < 0.0000000000000002 ***
## Income      -7.96351     0.28231  -28.21 < 0.0000000000000002 ***
## Limit        0.26842     0.00426   62.94 < 0.0000000000000002 ***
## Cards       24.67930     4.48609    5.50    0.000000087 ***
## Age        -0.20867     0.37506   -0.56     0.58
## Education   -2.86163     1.96620   -1.46     0.15
## StudentYes  437.40551    20.18559   21.67 < 0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 101 on 273 degrees of freedom
## Multiple R-squared:  0.955, Adjusted R-squared:  0.954
## F-statistic: 957 on 6 and 273 DF, p-value: <0.0000000000000002
```

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-457.408	38.621	-11.844	0.000	-533.441	-381.376
Income	-7.964	0.282	-28.209	0.000	-8.519	-7.408
Limit	0.268	0.004	62.940	0.000	0.260	0.277
Cards	24.679	4.486	5.501	0.000	15.848	33.511
Age	-0.209	0.375	-0.556	0.578	-0.947	0.530
Education	-2.862	1.966	-1.455	0.147	-6.732	1.009
StudentYes	437.406	20.186	21.669	0.000	397.666	477.145

4.5.1 Comentários e observações sobre o Modelo 3

O R^2 ajustado é 0,954 (praticamente inalterado em relação ao Modelo 2, que era 0,954). Remover três variáveis e cinco parâmetros não custou ajuste, confirmando que **Gender**, **Married** e **Ethnicity** eram irrelevantes para explicar o saldo.

Ainda restam variáveis com p-valores altos: **Education**, **Cards** e **Age** não apresentam evidência de contribuição significativa. Removemos as três no próximo passo.

4.6 Modelo 4 — remoção de Education, Cards e Age (modelo final)

As variáveis **Education**, **Cards** e **Age** apresentaram p-valores altos no Modelo 3 e correlações fracas com **Balance** na exploração inicial. Nenhuma delas contribui significativamente na presença de **Income**, **Limit** e **Student**. Removemos as três de uma vez:

```
##
## Call:
## lm(formula = Balance ~ Income + Limit + Student, data = treino)
##
## Residuals:
```

```
##      Min      1Q Median      3Q      Max
## -185.7  -79.5  -17.9   57.9  315.4
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -433.92121   15.11872  -28.7 <0.0000000000000002 ***
## Income      -8.07886    0.29088  -27.8 <0.0000000000000002 ***
## Limit        0.26992    0.00445   60.7 <0.0000000000000002 ***
## StudentYes  436.57993   21.22056   20.6 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 107 on 276 degrees of freedom
## Multiple R-squared:  0.949, Adjusted R-squared:  0.948
## F-statistic: 1.71e+03 on 3 and 276 DF,  p-value: <0.0000000000000002
```

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-433.921	15.119	-28.70	0	-463.684	-404.159
Income	-8.079	0.291	-27.77	0	-8.651	-7.506
Limit	0.270	0.004	60.70	0	0.261	0.279
StudentYes	436.580	21.221	20.57	0	394.805	478.355

A equação ajustada é:

$$\widehat{Balance} = -433,921 - 8,079 \text{ Income} + 0,270 \text{ Limit} + 436,580 Z_1.$$

4.6.1 Comentários e interpretação do Modelo 4

O R^2 ajustado é 0,948, praticamente idêntico ao do modelo completo com dez variáveis. Todas as variáveis são significativas:

- Mantendo **Limit** e **Student** constantes, cada US\$ 1.000 adicionais de renda estão associados a -8.078,864 dólares a **menos** no saldo. Entre clientes com o mesmo limite, quem tem renda maior carrega menos dívida.
- Mantendo **Income** e **Student** constantes, cada US\$ 1 adicional no limite está associado a 0,270 dólares a mais no saldo.
- Controlando as variáveis financeiras, estudantes carregam em média 436,580 dólares a mais que não estudantes.

A interpretação de **Income** é contraintuitiva à primeira vista: a renda mais alta associada a menor dívida, porém, faz sentido condicional: *dado o mesmo limite de crédito*, pessoas de maior renda tendem a usar uma fração menor do limite disponível.

variavel	VIF	raiz do VIF	tolerancia
Income	2.6	1.612	0.385
Limit	2.6	1.612	0.385
Student	1.0	1.000	1.000

Os VIF do modelo são todos baixos, confirmando ausência de multicolinearidade.

4.7 Modelo 5 — alternativa com Rating no lugar de Limit

No Modelo 1, removemos **Rating** por causa da colinearidade com **Limit**. Mas e se tivéssemos feito a escolha oposta? O Modelo 5 responde a essa pergunta, substituindo **Limit** por **Rating**:

```
##
## Call:
## lm(formula = Balance ~ Income + Rating + Student, data = treino)
##
## Residuals:
##      Min       1Q   Median       3Q      Max
## -219.59  -78.65   -8.85   61.38  294.62
##
## Coefficients:
##              Estimate Std. Error t value      Pr(>|t|)
## (Intercept) -582.6650    16.8408   -34.6 <0.0000000000000002 ***
## Income       -7.9954     0.2881   -27.8 <0.0000000000000002 ***
## Rating        4.0077     0.0656    61.1 <0.0000000000000002 ***
## StudentYes   429.1789    21.1028    20.3 <0.0000000000000002 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
##
## Residual standard error: 106 on 276 degrees of freedom
## Multiple R-squared:  0.95,    Adjusted R-squared:  0.949
## F-statistic: 1.73e+03 on 3 and 276 DF,  p-value: <0.0000000000000002
```

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-582.665	16.841	-34.60	0	-615.818	-549.512
Income	-7.995	0.288	-27.75	0	-8.563	-7.428
Rating	4.008	0.066	61.07	0	3.879	4.137
StudentYes	429.179	21.103	20.34	0	387.636	470.722

4.7.1 Comentários e interpretação do Modelo 5

O R^2 ajustado é 0,949, comparável ao do Modelo 4 (0,948). As duas variáveis colineares carregam informação semelhante, então trocar uma pela outra produz ajuste parecido. A diferença está na interpretação: **Limit** é uma quantidade em dólares diretamente compreensível, enquanto **Rating** é uma pontuação adimensional. Para comunicação e interpretação, o Modelo 4 com **Limit** é preferível.

4.8 Alterando a categoria de referência

Mudar a referência altera a forma dos coeficientes, mas não altera resíduos, valores ajustados, R^2 , AIC ou BIC.

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	2.659	24.293	0.109	0.913	-45.165	50.483

Income	-8.079	0.291	-27.774	0.000	-8.651	-7.506
Limit	0.270	0.004	60.700	0.000	0.261	0.279
StudentNo	-436.580	21.221	-20.573	0.000	-478.355	-394.805

Com **Yes** como referência, o coeficiente de **StudentNo** expressa o quanto não estudantes têm de saldo **menor**, em média condicional, do que estudantes. O sinal se inverte, mas o modelo é idêntico. O exemplo mostra que mudar a referência muda as comparações expressas pelos coeficientes, mas não muda o ajuste do modelo.

4.9 Seleção do modelo

A tabela abaixo reúne os cinco ajustes. Valores maiores de R^2 ajustado e menores de RQME residual, AIC e BIC são preferíveis.

- **R^2 ajustado:** parcela da variação explicada, com penalização pelo número de parâmetros;
- **RQME residual:** tamanho típico do erro de ajuste, em dólares;
- **AIC e BIC:** critérios que equilibram ajuste e complexidade; valores menores são preferíveis, e o BIC penaliza mais modelos complexos.

modelo	parametros	R2	R2_ajustado	RQME_residual	AIC	BIC
Modelo 1 — completo (10 preditores)	12	0.956	0.954	98.62	3392	3430
Modelo 2 — sem Rating	11	0.955	0.954	99.01	3392	3430
Modelo 3 — sem Gender, Married, Ethnicity	7	0.955	0.954	99.79	3388	3417
Modelo 4 — Income + Limit + Student	4	0.949	0.948	105.76	3415	3430
Modelo 5 — Income + Rating + Student	4	0.950	0.949	105.17	3412	3430

O R^2 ajustado permanece estável ao longo de toda a simplificação, mostrando que as variáveis removidas realmente não contribuíam. O BIC, que penaliza mais parâmetros extras, favorece os modelos mais simples. O Modelo 4 apresenta o melhor equilíbrio entre ajuste e parcimônia. O Modelo 5, com **Rating** no lugar de **Limit**, tem ajuste comparável, confirmando que as duas variáveis carregam essencialmente a mesma informação.

Os testes F abaixo verificam formalmente se cada grupo de variáveis removidas acrescentava informação.

4.9.1 Comparação 1 — Modelo 2 versus Modelo 1: contribuição de Rating

```
## Analysis of Variance Table
##
## Model 1: Balance ~ Income + Limit + Cards + Age + Education + Gender +
##      Student + Married + Ethnicity
## Model 2: Balance ~ Income + Limit + Rating + Cards + Age + Education +
##      Gender + Student + Married + Ethnicity
##   Res.Df    RSS Df Sum of Sq   F Pr(>F)
## 1      269 2745041
## 2      268 2723359   1    21682 2.13  0.15
```

4.9.2 Comparação 2 — Modelo 3 versus Modelo 2: contribuição de Gender, Married e Ethnicity

```
## Analysis of Variance Table
##
## Model 1: Balance ~ Income + Limit + Cards + Age + Education + Student
## Model 2: Balance ~ Income + Limit + Cards + Age + Education + Gender +
##      Student + Married + Ethnicity
##   Res.Df    RSS Df Sum of Sq   F Pr(>F)
## 1      273 2788130
## 2      269 2745041   4     43089 1.06  0.38
```

4.9.3 Comparação 3 — Modelo 4 versus Modelo 3: contribuição de Education, Cards e Age

```
## Analysis of Variance Table
##
## Model 1: Balance ~ Income + Limit + Student
## Model 2: Balance ~ Income + Limit + Cards + Age + Education + Student
##   Res.Df    RSS Df Sum of Sq   F   Pr(>F)
## 1      276 3131968
## 2      273 2788130   3     343838 11.2 0.00000058 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

4.9.4 Comparação 4 — Modelo 4 versus Modelo 5: Limit ou Rating?

Os Modelos 4 e 5 não são aninhados (usam preditores diferentes), portanto o teste F não se aplica. A comparação se dá pelos critérios de ajuste da tabela: R^2 ajustado, AIC e BIC. Ambos produzem ajustes semelhantes, mas **Limit** tem interpretação mais direta.

Em cada comparação aninhada, um p-valor alto indica que as variáveis removidas não acrescentavam ajuste significativo, confirmando a decisão de simplificar. O teste F responde a uma pergunta pontual: “este termo melhora este modelo reduzido?”. E ele só pode ser usado para modelos aninhados. AIC, BIC e R^2 ajustado comparam o equilíbrio geral entre ajuste e complexidade.

Modelo final: Modelo 4 — Balance ~ Income + Limit + Student. Partimos de um modelo completo com dez preditores e, a cada passo, verificamos que as variáveis removidas não contribuíam significativamente. O Modelo 4 mantém R^2 ajustado de 0,948, o menor BIC (3.433,05) e apenas três preditores, todos significativos, interpretáveis e sem colinearidade. O Modelo 5 confirma que trocar **Limit** por **Rating** produz ajuste equivalente, mas **Limit** é preferível pela interpretabilidade. A simplificação progressiva é confirmada tanto pelos testes F quanto pela estabilidade do R^2 ajustado.

5 Diagnóstico completo dos resíduos

O Modelo 4, selecionado como modelo final, será usado para a análise detalhada dos pressupostos. O diagnóstico verificará se sua forma linear é compatível com os dados.

5.1 O que verificaremos antes dos gráficos

O diagnóstico não procura um “gráfico perfeito”; ele verifica se há indícios fortes de que o modelo linear escolhido é inadequado. Antes de olhar a figura, estabeleça as perguntas de cada painel:

- **Linearidade:** os resíduos oscilam sem curvatura em torno de zero?
- **Homocedasticidade:** a dispersão dos resíduos se mantém semelhante ao longo dos valores ajustados?
- **Normalidade aproximada:** a distribuição dos resíduos é compatível com uma normal, especialmente nas caudas?
- **Alavancagem e influência:** existe algum cliente com combinação incomum de preditores e capacidade de alterar substancialmente o ajuste?

Essas verificações se complementam. Um único ponto fora de um limite não invalida o modelo; o interesse está em padrões persistentes e em sua relevância para a pergunta da análise.

5.2 Quatro gráficos fundamentais




Figura 7: Diagnóstico do Modelo 4. Linhas de referência servem como guias, não como decisões mecânicas.

5.2.1 Linearidade

O primeiro gráfico coloca no eixo horizontal os valores previstos pelo modelo e, no eixo vertical, os resíduos $e_i = y_i - \hat{y}_i$. Um resíduo positivo indica que o modelo subestimou o saldo devedor; um resíduo

negativo indica que o modelo superestimou.

O gráfico responde principalmente à pergunta: **a forma linear escolhida consegue representar a média da resposta?** O comportamento desejável é uma nuvem distribuída aleatoriamente ao redor de zero, com a linha suavizada aproximadamente horizontal. Uma forma em U ou U invertido sugeriria curvatura não representada; ondas poderiam indicar termos omitidos; grupos separados poderiam revelar que alguma estrutura categórica ainda não foi modelada.

5.2.2 Homocedasticidade

O terceiro gráfico, escala-localização, retira o sinal dos resíduos padronizados e destaca seu tamanho. Ele responde à pergunta: **a dispersão dos erros permanece aproximadamente constante para valores previstos pequenos e grandes?** Uma faixa de largura semelhante e uma linha suavizada horizontal são desejáveis. Um funil que se abre indicaria variância crescente; um funil que se fecha indicaria variância decrescente.

5.2.3 Normalidade aproximada

O QQ-plot compara os quantis dos resíduos padronizados com os quantis esperados de uma distribuição normal. A faixa dourada é um envelope simulado **heurístico** de 95%: ela mostra a variação esperada de uma amostra normal independente do mesmo tamanho. Resíduos padronizados de uma regressão não são observações independentes perfeitas; por isso, o envelope é apenas uma referência visual. Pontos sistematicamente fora da faixa, sobretudo nas caudas, sugerem desvio de normalidade; poucos pontos isolados podem ocorrer ao acaso.

O QQ-plot avalia a distribuição dos **resíduos**, e não exige que **Balance** ou os preditores sejam normalmente distribuídos. Essa normalidade é especialmente relevante para a qualidade dos testes, p-valores e intervalos de confiança em amostras pequenas. O envelope não avalia alavancagem ou influência: uma observação pode estar dentro do envelope de normalidade e, ainda assim, ter alavancagem alta.

```
## # A tibble: 1 x 3
##   teste          W `p-valor`
##   <chr>         <dbl>    <dbl>
## 1 Shapiro-Wilk 0.954      0
```

O teste de Shapiro-Wilk apresentou p-valor 0,0000. Este resultado deve ser interpretado em conjunto com o QQ-plot. Com amostras de 280 observações, testes podem detectar desvios irrelevantes do ponto de vista prático. Por isso, o gráfico e o teste devem ser lidos em conjunto.

5.2.4 Alavancagem e influência


O quarto gráfico combina três informações. A **alavancagem**, no eixo horizontal, mede quão incomum é a combinação de preditores de um cliente. A linha laranja é apenas um limite de triagem para alavancagem alta; ultrapassá-la significa que o cliente está em uma região pouco comum dos preditores, e **não** que ele seja uma observação errada ou que deva ser removido. O resíduo padronizado, no eixo vertical, mede quão distante sua resposta ficou do valor previsto. O tamanho do ponto representa a **distância de Cook**, que resume quanto o ajuste completo pode mudar quando aquela observação é retirada.

Uma observação com alavancagem alta não é automaticamente problemática: ela pode seguir perfeitamente a tendência. Uma observação com resíduo grande também pode ter pouca influência se estiver em uma região muito povoada dos preditores. A maior preocupação ocorre quando alavancagem alta e resíduo grande aparecem juntos, produzindo distância de Cook elevada.

Usando apenas referências de triagem, 40 observações ultrapassam $2p/n = 0,029$ e 25 ultrapassam $4/n = 0,014$ para a distância de Cook. A maior distância de Cook é 0,040.

5.2.5 Independência

A independência não pode ser confirmada por um gráfico se o desenho da coleta for desconhecido. Se vários registros vieram da mesma instituição financeira, agência ou período, talvez seja necessário um modelo hierárquico. Se as linhas estiverem ordenadas no tempo, avalie autocorrelação.



5.2.6 Investigando as observações sinalizadas

Tabela 13: Observações com maior distância de Cook

ID	Estudante	Renda	Limite	Saldo	Valor ajustado	Resíduo	Resíduo padr.	Alavancagem	Dist. Cook
294	No	140.67	11200	1677	1452.8	224.2	2.142	0.034	0.040
324	No	182.73	13913	1999	1845.3	153.7	1.492	0.065	0.030
242	No	15.60	906	0	-315.4	315.4	2.985	0.016	0.030
321	Yes	16.28	1160	5	184.3	-179.3	-1.723	0.046	0.030
86	No	152.30	12066	1779	1592.6	186.4	1.788	0.042	0.030
150	No	13.44	886	0	-303.4	303.4	2.870	0.016	0.030
219	Yes	10.63	1647	195	361.4	-166.4	-1.596	0.042	0.020
296	No	27.27	1389	0	-279.3	279.3	2.642	0.015	0.020
269	No	25.99	1349	0	-279.7	279.7	2.646	0.015	0.020
121	No	27.24	1402	0	-275.6	275.6	2.606	0.015	0.020
243	Yes	20.92	1233	16	166.5	-150.5	-1.447	0.046	0.020
351	No	30.00	1561	0	-255.0	255.0	2.411	0.015	0.020

Distância de Cook acima de $4/n$ é um sinal para investigar, não uma ordem para excluir. Primeiro verifique erro de digitação, compatibilidade com a população e sensibilidade das conclusões com e sem o ponto.

Análise de sensibilidade, não seleção de modelo. Os pontos abaixo são retirados apenas para verificar a estabilidade das conclusões. A comparação não deve ser usada para escolher um modelo com

R^2 maior nem para justificar exclusões automáticas.

Tabela 14: Métricas de ajuste na análise de sensibilidade

metrica	Todos os dados	Sem pontos sinalizados
R^2	0.949	0.963
R^2 ajustado	0.948	0.963
Erro-padrão residual	106.526	84.294

term	estimate_Todos os dados	estimate_Sem pontos sinalizados	std.error_Todos os dados	std.error_Sem pontos sinalizados
(Intercept)	-433.921	-480.150	15.119	15.119
Income	-8.079	-8.623	0.291	0.291
Limit	0.270	0.281	0.004	0.004
StudentYes	436.580	465.317	21.221	21.221

Foram sinalizadas 26 observações. Ao retirá-las apenas para esta análise de sensibilidade, o R^2 ajustado passa de 0,948 para 0,963 e o erro residual passa de 106,526 para 84,294. Essa aparente “melhora” é esperada quando removemos pontos com resíduos maiores; ela **não** prova que o modelo sem esses clientes é melhor ou que eles devam ser excluídos.

Os coeficientes permanecem próximos, como mostra a tabela. Portanto, o Modelo 4 ajustado com as 280 observações de treinamento continua sendo o resultado principal. Uma observação só deveria ser removida se houver evidência independente de erro de registro, de que ela não pertence à população estudada ou uma regra definida antes da análise, nunca apenas por cruzar a linha laranja, ter resíduo grande ou ficar dentro/fora do envelope.

6 Previsão e incerteza

Com o Modelo 4 selecionado, podemos estimar o saldo devedor para novos valores de `Income`, `Limit` e `Student`. Os nomes e tipos das colunas no novo `data.frame` precisam coincidir com os usados no ajuste.

cenario	Student	Income	Limit	intervalo	estimativa	inferior	superior
Cliente A	No	30	3000	IC 95% da média	133.5	116.89	150.1
Cliente B	Yes	70	5500	IC 95% da média	921.7	880.94	962.5
Cliente C	No	120	9000	IC 95% da média	1025.9	996.32	1055.5
Cliente A	No	30	3000	IP 95% individual	133.5	-76.88	343.8
Cliente B	Yes	70	5500	IP 95% individual	921.7	708.09	1135.4
Cliente C	No	120	9000	IP 95% individual	1025.9	814.15	1237.7

- **Intervalo de confiança da média:** captura a incerteza sobre o saldo médio esperado de todos os clientes com aquele conjunto de preditores.
- **Intervalo de previsão:** captura a incerteza para um novo cliente individual; incorpora a variação residual e, por isso, é sempre mais amplo para os mesmos valores dos preditores.

Para uma previsão individual, use o intervalo de previsão. Usar o intervalo de confiança da média nesse caso produz uma faixa estreita demais e aumenta a chance de não conter o valor individual observado.


7 Avaliação no conjunto de teste

Todo o percurso anterior foi realizado exclusivamente com o conjunto de **treinamento**. Agora aplicamos o Modelo 4 final ao conjunto de **teste**, 120 clientes que o modelo ainda não teve acesso, para avaliar sua capacidade preditiva em novas amostras.

metrica	valor
RQME (Erro quadrático médio residual)	99.863
EAM (Erro absoluto médio)	80.096
R ² no teste	0.948

Observado vs. previsto – conjunto de teste

Linha tracejada: previsão perfeita



O R² no teste mede o quanto da variância de **Balance** o modelo explica em clientes que **não participaram do ajuste**. Um R² alto e RQME próximo ao erro-padrão residual do treinamento indicam que o modelo generaliza bem e não está sobreajustado.

8 Conclusões finais

8.1 Síntese da exploração

A base contém 400 clientes, sem valores ausentes. **Limit** e **Rating** são fortemente correlacionadas entre si ($r \approx 0,997$), o que explica a multicolinearidade observada no modelo completo. A exploração gráfica mostrou que, entre as variáveis categóricas, apenas **Student** separa marcadamente os saldos devedores; **Gender**, **Married** e **Ethnicity** não apresentaram diferenças visuais relevantes, o que foi confirmado pelos p-valores e testes F ao longo da simplificação. Entre as variáveis numéricas, **Education**, **Cards** e **Age** não mostraram contribuição significativa na presença de **Income** e **Limit**.

8.2 Decisão e interpretação

Partimos de um modelo completo com dez preditores e o simplificamos progressivamente, removendo a cada passo as variáveis que não contribuíam significativamente. A cada remoção, o R^2 ajustado permaneceu estável e os testes F confirmaram que os termos removidos não acrescentavam informação. O resultado é o **Modelo 4**, com apenas três preditores, todos significativos, interpretáveis e sem colinearidade. O Modelo 5 confirmou que trocar **Limit** por **Rating** produz ajuste equivalente, mas **Limit** é preferível pela interpretabilidade.

No Modelo 4:

- mantendo **Limit** e **Student** constantes, US\$ 1.000 adicionais em **Income** estão associados a -8.078,864 dólares a **menos** em **Balance** — efeito negativo contraintuitivo que reflete uso proporcional do limite;
- mantendo **Income** e **Student** constantes, US\$ 1 adicional em **Limit** está associado a 0,270 dólares a mais em **Balance**;
- controlando as variáveis financeiras, estudantes carregam em média 436,580 dólares a mais que não estudantes.

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95% inferior	IC 95% superior
(Intercept)	-433.921	15.119	-28.70	0	-463.684	-404.159
Income	-8.079	0.291	-27.77	0	-8.651	-7.506
Limit	0.270	0.004	60.70	0	0.261	0.279
StudentYes	436.580	21.221	20.57	0	394.805	478.355

8.3 Verificação final dos pressupostos

Os gráficos de resíduos e escala-localização foram inspecionados e o teste de Shapiro–Wilk apresentou p-valor 0,0000. Os gráficos de alavancagem e distância de Cook foram examinados em conjunto e não revelaram uma observação isolada dominando completamente o modelo.

A independência não pode ser estabelecida apenas com a base. Se houver vários registros provenientes da mesma instituição, região ou período, seria necessário representar essa estrutura no modelo. As observações sinalizadas por influência também devem ser investigadas, não eliminadas automaticamente.

8.4 Conclusão substantiva

O saldo devedor do cartão de crédito está positivamente associado ao limite de crédito e à condição de estudante. A renda, depois de controlado o limite, apresenta associação negativa com o saldo: entre clientes com o mesmo limite, maior renda está ligada a menor endividamento. As demais variáveis disponíveis: classificação de crédito (removida por colinearidade com o limite), gênero, estado civil, etnia, anos de educação, número de cartões e idade não demonstraram contribuição independente significativa.

A simplificação progressiva (de dez para três preditores sem perda de ajuste) ilustra um princípio central da modelagem: mais variáveis não significam necessariamente um modelo melhor. Um modelo parcimonioso, com poucas variáveis bem justificadas, é mais interpretável, mais estável e menos sujeito a sobreajuste. O Modelo 5, com **Rating** no lugar de **Limit**, mostrou que as duas variáveis colineares carregam informação equivalente, validando a escolha de **Limit** pela interpretabilidade.

As conclusões são **associativas, não causais**. A base Credit é observacional e não contém detalhes suficientes do desenho da coleta para sustentar afirmações de causa e efeito.

Referências

BUSSAB, Wilton O.; MORETTIN, Pedro A. **Estatística Básica**. 9. ed. São Paulo: Saraiva, 2017.

PEREIRA, Adriano Scremin; MARCA, Luana; FILHO, Evandro José Perin Soares. **Regressão Linear Simples e Múltipla no R-Studio**. Passo Fundo: Universidade de Passo Fundo – PPGAdm, 2021.