

Regressão Linear Múltipla — Análise Completa da Base Credit

Estatística Aplicada — Universidade Federal de Campina Grande (UFCG)

Gustavo Maia Nogueira e Telmano Leite Japiassú Neto

03/08/2026

1 Introdução

O objetivo deste trabalho é investigar quais fatores estão associados ao saldo devedor do cartão de crédito de clientes bancários e avaliar se modelos de regressão linear múltipla são capazes de prever esse saldo com base em variáveis financeiras e demográficas. Formulamos a pergunta central como:

Entre clientes com o mesmo perfil financeiro e demográfico, como o saldo devedor esperado varia com cada preditor, e quão bem o modelo prevê novos clientes?

Essa formulação envolve dois objetivos complementares: por um lado, interpretar as relações condicionais entre preditores e resposta (inferência); por outro, estimar valores para novas observações com baixo erro (previsão). Partimos de um modelo completo com todos os preditores disponíveis e o simplificamos progressivamente, removendo variáveis que não contribuíam de forma significativa, até chegar a uma especificação parcimoniosa e defensável.

Para a observação i , o modelo geral que adotamos é

$$Y_i = \beta_0 + \beta_1 X_{1i} + \cdots + \beta_p X_{pi} + \varepsilon_i,$$

em que Y_i é o saldo devedor observado, β_0 é o valor esperado de Y quando os preditores valem zero, β_j é a mudança média esperada em Y para uma unidade adicional de X_j **mantendo os demais preditores constantes**, e ε_i representa tudo o que o modelo não explica. Quando incluímos variáveis categóricas, o R cria variáveis indicadoras (*dummies*) comparando cada nível com uma categoria de referência.

2 Dados e exploração

2.1 Estrutura e qualidade da base

```
## Rows: 400
## Columns: 13
## $ ID      <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 1~
## $ Income  <dbl> 14.89, 106.03, 104.59, 148.92, 55.88, 80.18, 21.00, 71.41, 1~
## $ Limit   <int> 3606, 6645, 7075, 9504, 4897, 8047, 3388, 7114, 3300, 6819, ~
## $ Rating  <int> 283, 483, 514, 681, 357, 569, 259, 512, 266, 491, 589, 138, ~
## $ Cards   <int> 2, 3, 4, 3, 2, 4, 2, 2, 5, 3, 4, 3, 1, 1, 2, 3, 3, 3, 1, 2, ~
```

```
## $ Age      <int> 34, 82, 71, 36, 68, 77, 37, 87, 66, 41, 30, 64, 57, 49, 75, ~
## $ Education <int> 11, 15, 11, 11, 16, 10, 12, 9, 13, 19, 14, 16, 7, 9, 13, 15, ~
## $ Gender   <fct> Male, Female, Male, Female, Male, Male, Female, Male, Female~
## $ Student  <fct> No, Yes, No, No, No, No, No, No, No, No, Yes, No, No, No, No~
## $ Married  <fct> Yes, Yes, No, No, Yes, No, No, No, No, No, Yes, Yes, No, Yes, Ye~
## $ Ethnicity <fct> Caucasian, Asian, Asian, Asian, Caucasian, Caucasian, Africa~
## $ Balance  <int> 333, 903, 580, 964, 331, 1151, 203, 872, 279, 1350, 1407, 0, ~
## $ id       <int> 1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 1~
```

Cada linha representa um cliente; o saldo devedor está em dólares. A base contém 400 observações.

Dividimos os dados em **280 observações de treinamento** (70%) e **120 de teste** (30%). Toda a exploração, ajuste e seleção de modelos utilizou apenas o conjunto de treinamento. O conjunto de teste ficou reservado para avaliação final da capacidade preditiva.

variavel	tipo	papel	definicao
Balance	numérica	resposta	saldo devedor do cartão de crédito (US\$)
Income	numérica	preditor	renda anual (milhares de US\$)
Limit	numérica	preditor	limite de crédito (US\$)
Rating	numérica	preditor	classificação de crédito
Cards	numérica	preditor	número de cartões de crédito
Age	numérica	preditor	idade (anos)
Education	numérica	preditor	anos de educação formal
Gender	categórica	preditor	gênero (Male / Female)
Student	categórica	preditor	status de estudante (Yes / No)
Married	categórica	preditor	estado civil (Yes / No)
Ethnicity	categórica	preditor	etnia (African American / Asian / Caucasian)
ID	inteira	identificador	identificador original do cliente

```
## observacoes duplicatas_exatas valores_ausentes estudantes nao_estudantes
## 1          400              0              0          40          360
```

2.2 Estatísticas descritivas

variavel	n	media	dp	minimo	q1	mediana	q3	maximo
Age	400	55.67	17.25	23.00	41.75	56.00	70.00	98.0
Balance	400	520.02	459.76	0.00	68.75	459.50	863.00	1999.0
Cards	400	2.96	1.37	1.00	2.00	3.00	4.00	9.0
Education	400	13.45	3.13	5.00	11.00	14.00	16.00	20.0
Income	400	45.22	35.24	10.35	21.01	33.12	57.47	186.6
Limit	400	4735.60	2308.20	855.00	3088.00	4622.50	5872.75	13913.0
Rating	400	354.94	154.72	93.00	247.25	344.00	437.25	982.0

2.3 Saldo devedor segundo as variáveis categóricas

Antes de ajustar qualquer modelo, examinamos graficamente se cada variável categórica separa o saldo devedor. Essa inspeção orientou quais variáveis mereciam entrar no modelo e antecipou quais provavelmente não teriam efeito significativo.

Saldo devedor por condição de estudante

Estudantes apresentam saldos consideravelmente mais altos




Figura 1: Saldo devedor por condição de estudante.

Observamos uma separação clara: estudantes carregam saldos devedores bem mais elevados do que não estudantes.

Saldo devedor por gênero

As distribuições se sobrepõem quase completamente




Figura 2: Saldo devedor por gênero.

Não identificamos separação visível entre os gêneros. As medianas, os quartis e a dispersão são praticamente idênticos.

Saldo devedor por estado civil

As distribuições são semelhantes para casados e não casados




Figura 3: Saldo devedor por estado civil.

As distribuições de casados e não casados se sobrepõem amplamente. O estado civil, por si só, não parece estar associado ao saldo devedor.

Saldo devedor por etnia

As três etnias apresentam distribuições praticamente sobrepostas




Figura 4: Saldo devedor por etnia.

As três etnias apresentam medianas, dispersões e formatos de distribuição muito semelhantes. Não encontramos evidência gráfica de associação entre etnia e saldo devedor.

Dos quatro preditores categóricos, apenas **Student** apresentou separação clara. **Gender**, **Married** e **Ethnicity** não mostraram diferenças visuais relevantes. Essa observação será confrontada com os p-valores nos modelos ajustados.

2.4 Distribuição do saldo devedor



Figura 5: Saldo devedor de cada cliente, ordenado por valor.

Uma parcela considerável dos clientes apresenta saldo devedor próximo de zero, formando um platô na parte inferior do gráfico. A partir daí, o saldo cresce de forma aproximadamente linear até os valores mais altos, que ultrapassam US\$ 1.500. Os estudantes (em dourado) concentram-se predominantemente na metade superior da distribuição, reforçando a separação já observada nos boxplots.

Essa concentração de valores próximos a zero é um indicativo que um modelo linear simples talvez não consiga descrever perfeitamente os dados.

2.5 Relações bivariadas




Figura 6: Matriz de pares: distribuições na diagonal, correlações no triângulo superior e dispersões no triângulo inferior.

##	Balance	Income	Limit	Rating	Cards	Age	Education
## Balance	1.000	0.464	0.862	0.864	0.086	0.002	-0.008
## Income	0.464	1.000	0.792	0.791	-0.018	0.175	-0.028
## Limit	0.862	0.792	1.000	0.997	0.010	0.101	-0.024
## Rating	0.864	0.791	0.997	1.000	0.053	0.103	-0.030
## Cards	0.086	-0.018	0.010	0.053	1.000	0.043	-0.051
## Age	0.002	0.175	0.101	0.103	0.043	1.000	0.004
## Education	-0.008	-0.028	-0.024	-0.030	-0.051	0.004	1.000

Dois padrões se destacam na matriz de correlação:

1. **Limit** e **Rating** têm correlação muito alta (0,997), sinalizando possível multicolinearidade severa se ambas entrarem no modelo.
2. **Balance** tem correlação forte com **Limit** (0,862) e **Rating** (0,864), moderada com **Income** (0,464), e fraca com **Cards**, **Age** e **Education**.

Vale lembrar que dois preditores positivamente correlacionados não precisam ter coeficientes com o mesmo sinal no modelo múltiplo. Cada coeficiente é um efeito parcial, condicionado aos demais termos,

e uma inversão de sinal pode revelar colinearidade ou confundimento, não uma contradição lógica.

3 Construção progressiva dos modelos

Partimos de um modelo completo contendo todas as variáveis disponíveis e, a cada passo, removemos as que não contribuíam de forma significativa, verificando com p-valores, gráficos exploratórios e testes F. Todos os cinco modelos foram ajustados com as 280 observações do conjunto de treinamento.

3.1 Modelo 1: modelo completo (todas as variáveis)

O primeiro ajuste inclui todos os preditores disponíveis. A partir da sua saída, identificamos quais variáveis não contribuem.

R ²	R ² ajustado	Erro-padrão residual	Estatística F	p-valor (F)	Parâmetros
0.9557	0.9539	100.8	525.4	0	12

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-497.385	45.914	-10.833	< 0,001	[-587,784; -406,987]
Income	-7.961	0.282	-28.203	< 0,001	[-8,516; -7,405]
Limit	0.209	0.041	5.088	< 0,001	[0,128; 0,290]
Rating	0.896	0.613	1.461	0,145	[-0,312; 2,103]
Cards	20.239	5.347	3.785	< 0,001	[9,712; 30,766]
Age	-0.216	0.374	-0.576	0,565	[-0,953; 0,521]
Education	-2.276	2.000	-1.138	0,256	[-6,214; 1,661]
GenderMale	17.264	12.122	1.424	0,156	[-6,603; 41,130]
StudentYes	435.935	20.385	21.385	< 0,001	[395,800; 476,070]
MarriedYes	-18.113	12.701	-1.426	0,155	[-43,119; 6,892]
EthnicityAsian	16.416	17.810	0.922	0,358	[-18,650; 51,482]
EthnicityCaucasian	15.363	15.720	0.977	0,329	[-15,587; 46,312]

Para avaliar a multicolinearidade, calculamos o VIF (*Variance Inflation Factor*) de cada preditor. O VIF indica por quanto a variância estimada de $\hat{\beta}_j$ está inflada pela relação linear entre os preditores: valores acima de 5 merecem atenção e acima de 10 indicam colinearidade forte.

variavel	VIF	raiz do VIF	tolerancia	R ² da regressão auxiliar
Income	2.734	1.654	0.366	0.634
Limit	247.388	15.729	0.004	0.996
Rating	248.726	15.771	0.004	0.996
Cards	1.439	1.200	0.695	0.305
Age	1.048	1.024	0.954	0.046
Education	1.049	1.024	0.953	0.047
Gender	1.012	1.006	0.988	0.012
Student	1.031	1.015	0.970	0.030
Married	1.049	1.024	0.953	0.047
Ethnicity	1.061	1.030	0.942	0.058

3.1.1 Observações sobre o Modelo 1

O modelo é globalmente significativo e apresenta R^2 ajustado igual a 0,954, ou aproximadamente 95,4% da variabilidade explicada. Identificamos dois problemas:

1. **Multicolinearidade severa entre Limit e Rating.** Os VIF dessas variáveis são extremamente altos: a correlação de 0,997 faz com que cada uma possa ser quase perfeitamente reconstruída pela outra. Isso infla os erros-padrão e torna os coeficientes individuais instáveis. Como **Limit** tem interpretação mais direta (é o próprio limite do cartão em dólares), optamos por remover **Rating** no próximo passo.
2. **Muitas variáveis com p-valor alto.** Diversas variáveis apresentam p-valores bem acima de 0,05, indicando que, condicionadas aos demais termos, não contribuem para explicar o saldo devedor. Isso é coerente com a exploração gráfica.

3.2 Modelo 2: remoção de Rating (colinearidade)

Removemos **Rating** e mantivemos todo o restante:

R^2	R^2 ajustado	Erro-padrão residual	Estatística F	p-valor (F)	Parâmetros
0.9553	0.9537	101	575.3	0	11

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-468.454	41.510	-11.285	< 0,001	[-550,179; -386,729]
Income	-7.943	0.283	-28.107	< 0,001	[-8,499; -7,387]
Limit	0.268	0.004	62.901	< 0,001	[0,260; 0,277]
Cards	24.477	4.501	5.439	< 0,001	[15,616; 33,338]
Age	-0.219	0.375	-0.585	0,559	[-0,958; 0,519]
Education	-2.812	1.970	-1.427	0,155	[-6,691; 1,066]
GenderMale	16.510	12.137	1.360	0,175	[-7,385; 40,405]
StudentYes	438.270	20.365	21.521	< 0,001	[398,174; 478,365]
MarriedYes	-15.565	12.607	-1.235	0,218	[-40,386; 9,255]
EthnicityAsian	13.821	17.759	0.778	0,437	[-21,142; 48,785]
EthnicityCaucasian	15.090	15.752	0.958	0,339	[-15,922; 46,102]

variavel	VIF	raiz do VIF	tolerancia
Income	2.729	1.652	0.366
Limit	2.664	1.632	0.375
Cards	1.015	1.008	0.985
Age	1.048	1.024	0.954
Education	1.014	1.007	0.986
Gender	1.010	1.005	0.990
Student	1.024	1.012	0.976
Married	1.030	1.015	0.971
Ethnicity	1.046	1.023	0.956

3.2.1 Observações sobre o Modelo 2

Com a remoção de **Rating**, nenhum VIF está em faixa preocupante. O R^2 ajustado permaneceu em 0,954, mostrando que **Rating** não acrescentava informação que **Limit** já não fornecesse. Com os erros-padrão estabilizados, os p-valores confirmam que **Student**, **Income** e **Limit** são significativos, enquanto **Gender**, **Married**, **Ethnicity**, **Education**, **Cards** e **Age** não apresentam evidência de contribuição.

3.3 Modelo 3: remoção de Gender, Married e Ethnicity

A exploração gráfica mostrou que essas três variáveis categóricas não separam o saldo devedor, e os p-valores no Modelo 2 confirmaram a ausência de contribuição significativa:

R^2	R^2 ajustado	Erro-padrão residual	Estatística F	p-valor (F)	Parâmetros
0.9546	0.9536	101.1	957.4	0	7

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-457.408	38.621	-11.844	< 0,001	[-533,441; -381,376]
Income	-7.964	0.282	-28.209	< 0,001	[-8,519; -7,408]
Limit	0.268	0.004	62.940	< 0,001	[0,260; 0,277]
Cards	24.679	4.486	5.501	< 0,001	[15,848; 33,511]
Age	-0.209	0.375	-0.556	0,578	[-0,947; 0,530]
Education	-2.862	1.966	-1.455	0,147	[-6,732; 1,009]
StudentYes	437.406	20.186	21.669	< 0,001	[397,666; 477,145]

3.3.1 Observações sobre o Modelo 3

O R^2 ajustado é 0,954, praticamente inalterado em relação ao Modelo 2 (0,954). Remover três variáveis e cinco parâmetros não custou ajuste. **Education** e **Age** permanecem com p-valores altos. **Cards** possui correlação fraca com **Balance** na exploração inicial e a instabilidade do seu p-valor entre especificações sugerem que sua contribuição é marginal. Testamos a remoção das três no próximo passo e verificamos com o teste F se houve perda de ajuste.

3.4 Modelo 4: Income + Limit + Student (modelo final)

As variáveis **Education** e **Age** apresentaram p-valores altos no Modelo 3, e **Cards**, baixíssima correlação com a variável resposta. Removemos as três e verificamos a perda de ajuste com o teste F:

R^2	R^2 ajustado	Erro-padrão residual	Estatística F	p-valor (F)	Parâmetros
0.949	0.9485	106.5	1713	0	4

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-433.921	15.119	-28.70	< 0,001	[-463,684; -404,159]
Income	-8.079	0.291	-27.77	< 0,001	[-8,651; -7,506]
Limit	0.270	0.004	60.70	< 0,001	[0,261; 0,279]
StudentYes	436.580	21.221	20.57	< 0,001	[394,805; 478,355]

A equação ajustada é:

$$\widehat{Balance} = -433,921 - 8,079 \text{ Income} + 0,270 \text{ Limit} + 436,580 Z_1.$$

3.4.1 Interpretação do Modelo 4

O R^2 ajustado é 0,948, praticamente idêntico ao do modelo completo com dez variáveis. Todos os coeficientes são significativos:

- Mantendo **Limit** e **Student** constantes, cada US\$ 1.000 adicionais de renda estão associados a -8.078,864 dólares a **menos** no saldo. Entre clientes com o mesmo limite, quem tem renda maior carrega menos dívida.
- Mantendo **Income** e **Student** constantes, cada US\$ 1 adicional no limite está associado a 0,270 dólares a mais no saldo.
- Controlando as variáveis financeiras, estudantes carregam em média 436,580 dólares a mais que não estudantes.

A associação negativa de **Income** faz sentido condicional: *dado o mesmo limite de crédito*, pessoas de maior renda tendem a usar uma fração menor do limite disponível.

variavel	VIF	raiz do VIF	tolerancia
Income	2.6	1.612	0.385
Limit	2.6	1.612	0.385
Student	1.0	1.000	1.000

Os VIF do Modelo 4 são todos baixos, confirmando ausência de multicolinearidade.

3.5 Modelo 5: alternativa com Rating no lugar de Limit

Para verificar a consequência da escolha entre as duas variáveis colineares, ajustamos um modelo alternativo substituindo **Limit** por **Rating**:

R^2	R^2 ajustado	Erro-padrão residual	Estatística F	p-valor (F)	Parâmetros
0.9496	0.9491	105.9	1734	0	4

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-582.665	16.841	-34.60	< 0,001	[-615,818; -549,512]
Income	-7.995	0.288	-27.75	< 0,001	[-8,563; -7,428]
Rating	4.008	0.066	61.07	< 0,001	[3,879; 4,137]
StudentYes	429.179	21.103	20.34	< 0,001	[387,636; 470,722]

O R^2 ajustado é 0,949, comparável ao do Modelo 4 (0,948). As duas variáveis colineares carregam informação semelhante, então trocar uma pela outra produz ajuste parecido. A diferença está na interpretação: **Limit** é uma quantidade em dólares diretamente compreensível, enquanto **Rating** é uma pontuação adimensional. Para comunicação, preferimos o Modelo 4.

3.6 Efeito da categoria de referência

Para a variável categórica **Student**, foi modelado um booleano indicando se a amostra é estudante, a seguir, mostramos como a escolha do valor de referência não tem impacto significativo.

Para ilustrar que a escolha da categoria de referência afeta a forma dos coeficientes mas não o modelo em si, reajustamos o Modelo 4 usando **Yes** como referência de **Student**:

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	2.659	24.293	0.109	0,913	[-45,165; 50,483]
Income	-8.079	0.291	-27.774	< 0,001	[-8,651; -7,506]
Limit	0.270	0.004	60.700	< 0,001	[0,261; 0,279]
StudentNo	-436.580	21.221	-20.573	< 0,001	[-478,355; -394,805]

Com **Yes** como referência, o coeficiente de **StudentNo** expressa o quanto não estudantes têm de saldo menor, em média condicional, do que estudantes. O sinal se inverte, mas resíduos, valores ajustados, R^2 , AIC e BIC permanecem idênticos.

3.7 Seleção do modelo

A tabela abaixo reúne os cinco ajustes. Valores maiores de R^2 ajustado e menores de RQME residual, AIC e BIC são preferíveis.

modelo	parametros	R2	R2_ajustado	RQME_residual	AIC	BIC
Modelo 1	12	0.956	0.954	98.62	3392	3439
Modelo 2	11	0.955	0.954	99.01	3392	3436
Modelo 3	7	0.955	0.954	99.79	3388	3417
Modelo 4	4	0.949	0.948	105.76	3415	3433
Modelo 5	4	0.950	0.949	105.17	3412	3430

O R^2 ajustado permaneceu estável ao longo de toda a simplificação, mostrando que as variáveis removidas não contribuíam. O BIC, que penaliza mais parâmetros extras, favorece os modelos mais simples. Os testes F abaixo verificam formalmente se cada grupo de variáveis removidas acrescentava informação.

Comparação	GL removidos	F	p-valor
Modelo 2 vs 1 (Rating)	1	2.134	0,145
Modelo 3 vs 2 (Gender, Married, Ethnicity)	4	1.056	0,379
Modelo 4 vs 3 (Education, Cards, Age)	3	11.222	< 0,001

Em cada comparação, um p-valor alto indica que as variáveis removidas não acrescentavam ajuste significativo, confirmando a simplificação. Os Modelos 4 e 5 não são aninhados (usam preditores diferentes), portanto o teste F não se aplica; a comparação entre eles se deu pelos critérios de ajuste da tabela anterior.

Modelo final: Modelo 4 — Balance ~ Income + Limit + Student. Partimos de um modelo completo com dez preditores e, a cada passo, verificamos que as variáveis removidas não contribuíam significativamente. O Modelo 4 apresenta R^2 ajustado de 0,948, o menor BIC (3.433,05) e apenas três preditores, todos significativos, interpretáveis e sem colinearidade.

4 Diagnóstico dos resíduos

Aplicamos o diagnóstico ao Modelo 4, selecionado como modelo final, para verificar se a forma linear é compatível com os dados.

4.1 Linearidade




Figura 7: Resíduos versus valores ajustados.

A linha suavizada mostra uma curvatura: os resíduos tendem a ser positivos para valores ajustados baixos (abaixo de ~200), negativos na faixa intermediária e novamente positivos para valores altos. Esse padrão em U indica que a relação linear não captura completamente a estrutura dos dados, sugerindo que termos adicionais (polinomiais ou interações) poderiam melhorar o ajuste. Apesar disso, o desvio é moderado e o modelo ainda explica cerca de 95% da variabilidade.

4.2 Homocedasticidade




Figura 8: Gráfico escala-localização.

A linha suavizada apresenta uma leve inclinação ascendente: a dispersão dos resíduos aumenta para valores ajustados mais altos. Isso sugere heterocedasticidade moderada, com clientes de saldo previsto alto apresentando erros mais variáveis do que aqueles com saldo previsto baixo. A violação não é severa,

mas seria prudente considerar erros-padrão robustos se a inferência exata dos coeficientes fosse o objetivo principal.

4.3 Normalidade aproximada




Figura 9: QQ-plot com envelope simulado de 95%.

O QQ-plot revela desvios nas duas caudas: na cauda inferior, os resíduos são menos negativos do que o esperado por uma normal, e na cauda superior, são mais positivos. Vários pontos excedem o envelope simulado de 95%, indicando caudas mais pesadas do que a distribuição normal prevê. Isso é coerente com a presença de clientes cujo saldo devedor real se afasta consideravelmente do previsto pelo modelo.

teste	W	p-valor
Shapiro-Wilk	0,9539	< 0,001

O teste de Shapiro-Wilk rejeita a hipótese de normalidade ($p\text{-valor} < 0,001$), confirmando o que o QQ-plot já indicava. Com 280 observações, o teste é sensível a desvios pequenos; ainda assim, o desvio aqui é visualmente perceptível. Na prática, com amostras desse tamanho, os estimadores de MQO continuam consistentes e os intervalos de confiança são razoavelmente robustos, mas a inferência exata baseada na distribuição t deve ser interpretada com cautela.

4.4 Alavancagem e influência




Figura 10: Alavancagem versus resíduo padronizado. Tamanho proporcional à distância de Cook.

Do total de observações, 40 ultrapassam o limiar de alavancagem $2p/n = 0,029$ e 25 ultrapassam $4/n = 0,014$ para a distância de Cook. A maior distância de Cook observada é 0,040, bem abaixo do limiar conservador de 1. Não identificamos nenhuma observação isolada com influência dominante sobre o ajuste. Os pontos de maior alavancagem tendem a ser clientes com combinações extremas de renda e limite, mas seus resíduos não são grandes o suficiente para alterar substancialmente os coeficientes.

4.5 Independência




Figura 11: Resíduos na ordem das observações.

O gráfico de resíduos na ordem das observações não apresenta padrões de autocorrelação visíveis: não há tendências, ciclos ou agrupamentos sistemáticos. Como não temos informação sobre a estrutura temporal ou de agrupamento da coleta, a independência não pode ser formalmente confirmada, mas também não encontramos evidência contra ela nos dados disponíveis.

4.5.1 Observações sinalizadas

Tabela 20: Observações com maior distância de Cook

ID	Estud.	Renda	Ajustado	Resíduo	Res. padr.	Dist. Cook	Sinal.
294	No	140.67	1452.8	224.2	2.142	0.040	TRUE
324	No	182.73	1845.3	153.7	1.492	0.039	TRUE
242	No	15.60	-315.4	315.4	2.985	0.036	TRUE
321	Yes	16.28	184.3	-179.3	-1.723	0.036	TRUE
86	No	152.30	1592.6	186.4	1.788	0.035	TRUE
150	No	13.44	-303.4	303.4	2.870	0.032	TRUE
219	Yes	10.63	361.4	-166.4	-1.596	0.028	TRUE
296	No	27.27	-279.3	279.3	2.642	0.027	TRUE
269	No	25.99	-279.7	279.7	2.646	0.027	TRUE
121	No	27.24	-275.6	275.6	2.606	0.026	TRUE
243	Yes	20.92	166.5	-150.5	-1.447	0.025	TRUE
351	No	30.00	-255.0	255.0	2.411	0.022	TRUE

Distância de Cook acima de $4/n$ é um sinal para investigar, não uma ordem para excluir. Para avaliar a estabilidade das conclusões, realizamos uma análise de sensibilidade retirando as observações sinalizadas.

Tabela 21: Métricas de ajuste na análise de sensibilidade

metrica	Todos os dados	Sem pontos sinalizados
R^2	0.949	0.963
R^2 ajustado	0.948	0.963
Erro-padrão residual	106.526	84.294

termo	Todos: estimativa	Sem sinal.: estimativa	Todos: erro-padrão	Sem sinal.: erro-padrão
(Intercept)	-433.921	-480.150	15.119	14.132
Income	-8.079	-8.623	0.291	0.242
Limit	0.270	0.281	0.004	0.004
StudentYes	436.580	465.317	21.221	19.237

Foram sinalizadas 26 observações. Ao retirá-las, o R^2 ajustado passa de 0,948 para 0,963 e o erro residual passa de 106,526 para 84,294. Essa aparente melhora é esperada quando removemos pontos com resíduos maiores e não prova que eles devam ser excluídos. Os coeficientes permanecem próximos, confirmando a estabilidade do Modelo 4.

5 Previsão e incerteza

Com o Modelo 4 selecionado, estimamos o saldo devedor para três perfis hipotéticos de clientes.

cenario	Student	Income	Limit	intervalo	estimativa	inferior	superior
Cliente A	No	30	3000	IC 95% da média	133.5	116.89	150.1
Cliente B	Yes	70	5500	IC 95% da média	921.7	880.94	962.5
Cliente C	No	120	9000	IC 95% da média	1025.9	996.32	1055.5


Cliente A	No	30	3000	IP 95% individual	133.5	-76.88	343.8
Cliente B	Yes	70	5500	IP 95% individual	921.7	708.09	1135.4
Cliente C	No	120	9000	IP 95% individual	1025.9	814.15	1237.7

O **intervalo de confiança da média** captura a incerteza sobre o saldo médio esperado de todos os clientes com aquele perfil. O **intervalo de previsão** captura a incerteza para um novo cliente individual e é sempre mais amplo, pois incorpora a variação residual.

6 Avaliação no conjunto de teste

Aplicamos o Modelo 4 ao conjunto de teste (120 clientes que não participaram do ajuste) para avaliar a capacidade preditiva em dados novos.

metrica	valor
RQME (Erro quadrático médio residual)	99.863
EAM (Erro absoluto médio)	80.096
R ² no teste	0.948



Um R² alto no teste e RQME próximo ao erro-padrão residual do treinamento indicam que o modelo não está sobreajustado.

7 Conclusões

7.1 Síntese

A base contém 400 clientes, sem valores ausentes. **Limit** e **Rating** são fortemente correlacionadas entre si ($r \approx 0,997$), o que explica a multicolinearidade observada no modelo completo. Entre as variáveis categóricas, apenas **Student** separa marcadamente os saldos devedores. As demais (**Gender**, **Married**, **Ethnicity**) não apresentaram diferenças relevantes, o que os p-valores e testes F confirmaram. Entre as

variáveis numéricas, **Education**, **Cards** e **Age** não mostraram contribuição significativa na presença de **Income** e **Limit**.

7.2 Modelo selecionado e interpretação

Partimos de um modelo completo com dez preditores e o simplificamos progressivamente. A cada remoção, o R^2 ajustado permaneceu estável e os testes F confirmaram que os termos removidos não acrescentavam informação. O resultado é o Modelo 4, com três preditores, todos significativos, interpretáveis e sem colinearidade:

- Mantendo **Limit** e **Student** constantes, US\$ 1.000 adicionais em **Income** estão associados a -8.078,864 dólares a **menos** em **Balance**.
- Mantendo **Income** e **Student** constantes, US\$ 1 adicional em **Limit** está associado a 0,270 dólares a mais em **Balance**.
- Controlando as variáveis financeiras, estudantes carregam em média 436,580 dólares a mais que não estudantes.

termo	estimativa	erro-padrão	estatistica_t	p-valor	IC 95%
(Intercept)	-433.921	15.119	-28.70	< 0,001	[-463,684; -404,159]
Income	-8.079	0.291	-27.77	< 0,001	[-8,651; -7,506]
Limit	0.270	0.004	60.70	< 0,001	[0,261; 0,279]
StudentYes	436.580	21.221	20.57	< 0,001	[394,805; 478,355]

7.3 Limitações do modelo

Os gráficos de resíduos e o teste de normalidade dos erros, corroborado pela suspeita inicial de não linearidade dos dados, indica que um modelo linear simples pode não ser a melhor abordagem devido a natureza das variáveis:

7.3.1 Assimetria do saldo devedor

Como é de se esperar do domínio, o saldo devedor é uma grandeza com alta assimetria, o zero é um valor muito mais comum e um modelo de predição que depende de dados simétricos naturalmente é prejudicado por essa natureza

7.3.2 Normalidade dos erros

Conforme o gráfico do QQ-Plot apontou, e o plot das previsões do modelo 4 confirmaram, os erros não são normais, existe uma clara tendência do modelo em subestimar saldos maiores e superestimar saldos próximos ou iguais a zero. Note que como os casos onde o saldo devedor é 0 são muito numerosos, esses causam um efeito de alavancagem reduzindo a inclinação da reta, o que causa esse efeito negativo mesmo na parte dos dados que pode ser explicada linearmente.

Note ainda que é possível se treinar um modelo que consegue performar bem nos casos com saldo devedor positivo ao ser treinado apenas considerando esses casos.

7.4 Alternativas ao modelo linear

Dado a incapacidade do modelo linear em expressar a relação das outras variáveis com o saldo devedor, outras abordagens devem ser consideradas para melhor descrever a relação do saldo devedor com as outras variáveis, algumas possibilidades são:

7.4.1 Modelos não lineares

Modelos não lineares como o perceptron podem representar relações não-lineares como a do saldo devedor perfeitamente, podendo se tornar o caminho ideal para esse caso

7.4.2 Modelos zero-inflados

Modelos zero-inflados são modelos que expressam corretamente essa assimetria, na prática, existem dois modelos internos, sendo um dos modelos especializado em detectar se a amostra pertence ao grupo do zero, e caso não seja, um modelo linear para prever o seu valor real.

Considerando o desenho amostral da variável de saldo devedor, modelos lineares zero-inflados podem descrever de forma muito satisfatória essa variável.

Referências

BUSSAB, Wilton O.; MORETTIN, Pedro A. **Estatística Básica**. 9. ed. São Paulo: Saraiva, 2017.

PEREIRA, Adriano Scremin; MARCA, Luana; FILHO, Evandro José Perin Soares. **Regressão Linear Simples e Múltipla no R-Studio**. Passo Fundo: Universidade de Passo Fundo – PPGAdm, 2021.